Analisi di una Base di Dati Genetici e Sviluppo di un Modello Predittivo tramite Machine Learning

Corso di laurea in Informatica
Sabrina Natili

Anno Accademico 2024-2025

SAPIENZA
UNIVERSITÀ DI ROMA

Facoltà di Ingegneria dell'informazione, Informatica e Statistica
Dipartimento di Informatica

Relatore: Prof. Maurizio Mancini

Indice

1. Introduzione

►Introduzione

►Database

►Algoritmo predittivo

►Risultati

►Conclusioni

Obiettivi della Ricerca

- **L’integrazione tra informatica avanzata** e **biomedicina** ha dato vita alla **medicina di precisione**, con un’attenzione particolare alla **prevenzione,** una **diagnosi precoce** e la **personalizzazione dei trattamenti**

- Lo scopo è quello di sviluppare un algoritmo che **riesca a predire il più correttamente possible se la persona risulta viva o deceduta** in base alle **misurazioni dell’espressione genica di tipo TPM.**

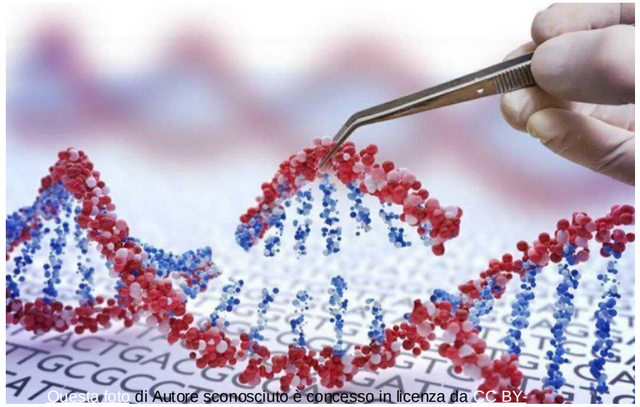

Questa foto di Autore sconosciuto è concesso in licenza da CC BY-

L'espressione genica e l'importanza dei biomarcatori

L'**espressione genica** è il processo con cui l'**informazione** contenuta nel **DNA** viene convertita in proteine funzionali.

Permette di identificare i **biomarcatori**: indicatori biologici, come una sequenza di DNA o una proteina, che aiutano a **rilevare i tumori.** Si dividono in tre tipi:

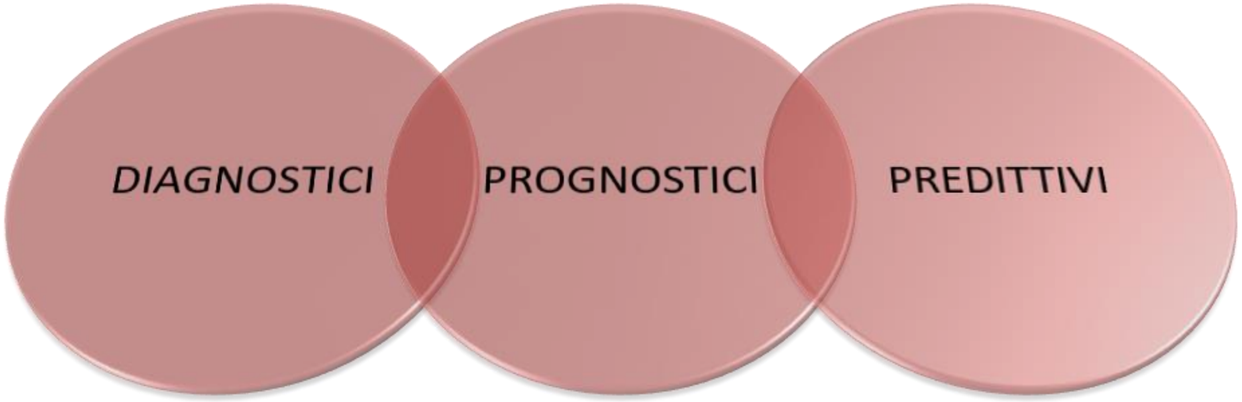

Utilità della Ricerca in ottica futura

Il tipo di predizione che vogliamo fare assume **grande importanza clinica e scientifica**.

- Prognosi personalizzata
- Ottimizzazione Trattamenti
- Identif. Biomarcatore Prognostici
- Diagnosi Precoce E Prevenzione Recidive
- Applicazione Modelli Ml

Papillomi e Carcinomi a Cellule di Transizione

Il sito preso in esame è la **vescica**

→ tumore dei tessuti molli e sarcomi

→ **papillomi e carcinomi a cellule di transizione**

→ neoplasie

Il tumore alla vescica è uno dei **tumori urologici più comuni, con un aumento dell'8%** nelle diagnosi annuali negli ultimi tempi. La probabilità di sopravvivenza dell'80% dopo i primi 5 anni. La **possibilità di recidiva arriva però fino al 78%.**

I dati sono stati ricavati dal **GDC (Genomic Data Commons),** una piattaforma dove al suo interno troviamo i dataset genomici sul cancro più grandi e completi che esistano.

Indice

2. Creazione del Database

- Introduzione
- Creazione del Database
- Algoritmo predittivo
- Risultati
- Conclusioni

Le tabelle Gene Expression File e Case

- La Base di Dati creata ha avuto **come fonte diretta un database già esistente.**

- Le analisi sono presentate sotto forma di **Gene Expression File**, un insieme strutturato di dati che rappresenta le **quantità di espressione genica in campioni biologici**.

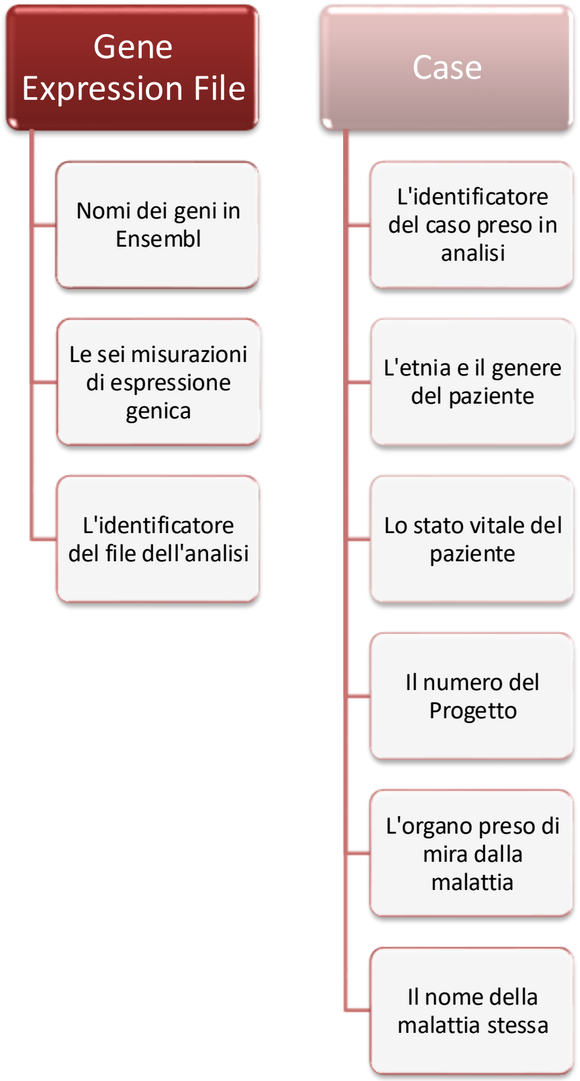

Extract, Transform e Load

1. Ripeschiamo tutti i **nomi di geni** presenti nella tabella Gene Expression File e li **associamo correttamente al nome delle sei misure** che abbiamo scelto di considerare. Ogni nome di gene avrà il suo **identificatore serial**.

measure_id [PK] integer	name text	unita_misura text
1	ENSG00000204671.2	tpm

2. Popoliamo una seconda tabella, rispettando i vincoli imposti dalla chiave esterna, con le **misurazioni dell'espressione genica** associati al gene, che potrà essere presente in più analisi.

measure_id [PK] integer	sample_id [PK] integer	measure_value text
1	28	0.1004

3. Con una terza tabella teniamo traccia di tutti **i nomi delle analisi** presenti nel database di partenza.

analysis_id [PK] integer	analysis_data text
28	2279f129-d06d-43f7-9f16-6e8d3a4feb56

analysis [PK] text	gene [PK] text	tpm numeric
2279f129-d06d-43f7-9f16-6e8d3a4feb56	ENSG00000204671.2	0.1004

Se andiamo a controllare i dati infatti sono stati estratti e inseriti correttamente

Indice

3. Algoritmo predittivo

- Introduzione
- Creazione del Database
- Algoritmo predittivo
- Risultati
- Conclusioni

Alberi decisionali e XGBoost

Consapevolezza della cache e calcolo out-of-core

Regolarizzazione per evitare l'overfitting

Potatura degli alberi utilizzando un approccio depth-first

Gestione efficiente dei dati mancanti

Costruzione parallela degli alberi

Capacità di cross-validazione integrata

Codice e implementazione: Connessione al Database e Importazione dei dati

I dati vengono organizzati in due **Dataframe**:

- Il primo per associare ogni campione allo stato vitale
- Il secondo per avere tutti gli identificatori delle analisi ordinati per ciascuna riga, con i geni corrispondenti.

Abbiamo diviso quindi in X (Features/Caratteristiche) e Y (Target/Variabile dipendente) i dati:

X $\longrightarrow$ **corrispondono i geni**

Y $\longrightarrow$ **stato vitale**

Gestione dei dati mancanti

Grande quantità di Nan → **Threshold del 40% sulle colonne del Dataframe**

Nan rimanenti → **Sostituiti da zeri**

Addestramento del modello e tecniche di bilanciamento

1. STANDARDIZZAZIONE

- Essenziale per **evitare** che **feature con scale diverse** assumano più importanza le une sulle altre

2. DIVISIONE TRA TRAIN-SET E TEST-SET

- **75%** dei dati nell'addestramento; **25%** per i test

3. BILANCIAMENTO CON SMOTE

- Genera **nuovi esempi sintetici** per la classe che risulta minoritaria.

L’XGBClassifier e l’impiego di RandomizeSearchCV

```
# Definizione del modello base
xgb_model = xgb.XGBClassifier(eval_metric=['auc', 'logloss','error'], scale_pos_weight=scale_pos_weight, random_state=42,n_jobs=2 )
```

XGBClassifier è una classe della libreria XGBoost utilizzata per problemi di classificazione.

```
# Griglia dei parametri per la ricerca
param_dist = {
    'n_estimators': [100, 200, 300, 500],
    'max_depth': [3, 5, 10, 50,100],
    'learning_rate': [0.01, 0.1,0.3],
    'subsample': [0.7, 0.8, 0.9, 1.0],
    'colsample_bytree': [0.5, 0.7, 0.8, 1.0],
    'gamma': [0, 1, 5, 10,100],
    'min_child_weight': [1, 3, 5, 20,100]
}
```

RandomizedSearchCV è una tecnica di **tuning degli iperparametri**, o hyperparameter optimization, in Scikit-Learn che cerca di trovare la **combinazione migliore di iperparametri** per un modello di Machine Learning.

```
# Configurazione di RandomizedSearchCV
random_search = RandomizedSearchCV(
    estimator=xgb_model,
    param_distributions=param_dist,
    n_iter=100,  # Numero di combinazioni casuali da testare
    scoring='accuracy',
    cv=KFold(n_splits=5, shuffle=True, random_state=42),
    verbose=2,
    random_state=42,
    n_jobs=2
)
```

Confusion Matrix

La **Confusion Matrix** è una tabella che mostra il confronto tra le **predizioni** fatte dal modello e i **valori reali** della classe target.

Ci aiuta a calcolare diverse metriche di valutazione come:

- **Accuracy**
- **Precision**
- **Recall (Sensibilità)**
- **F1-score**

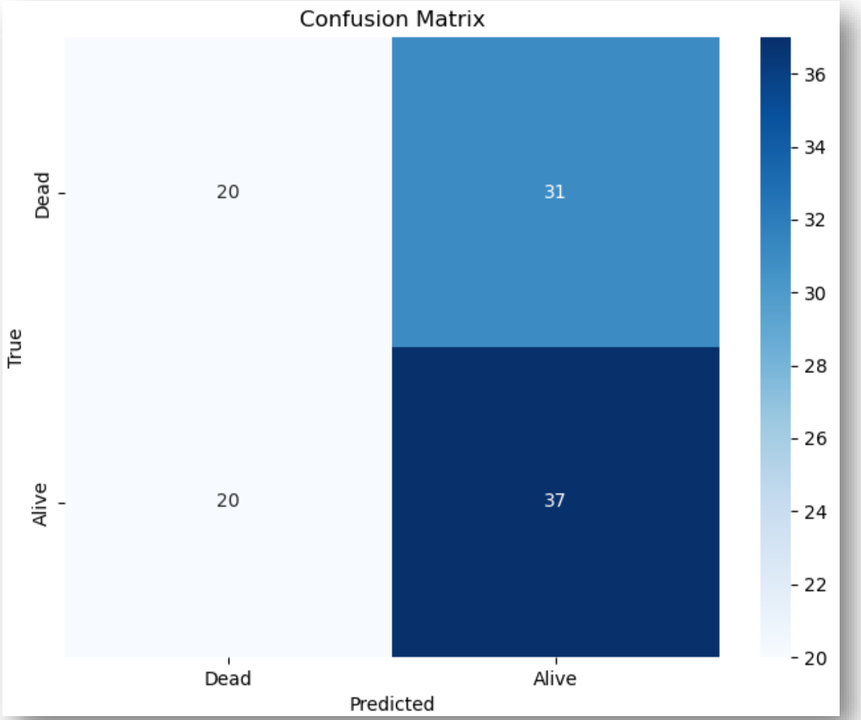

K-Fold Cross-Validation

La **Cross-Validation** (validazione incrociata) è una tecnica utilizzata per valutare le prestazioni di un modello di Machine Learning in modo più affidabile, evitando problemi come l'**overfitting** o il **bias del dataset**.

Suddivide il dataset in più parti (o "folds") e ripete il processo di addestramento e test più volte, cambiando ogni volta la parte usata per il test. Alla fine si calcola la media delle metriche ottenute.

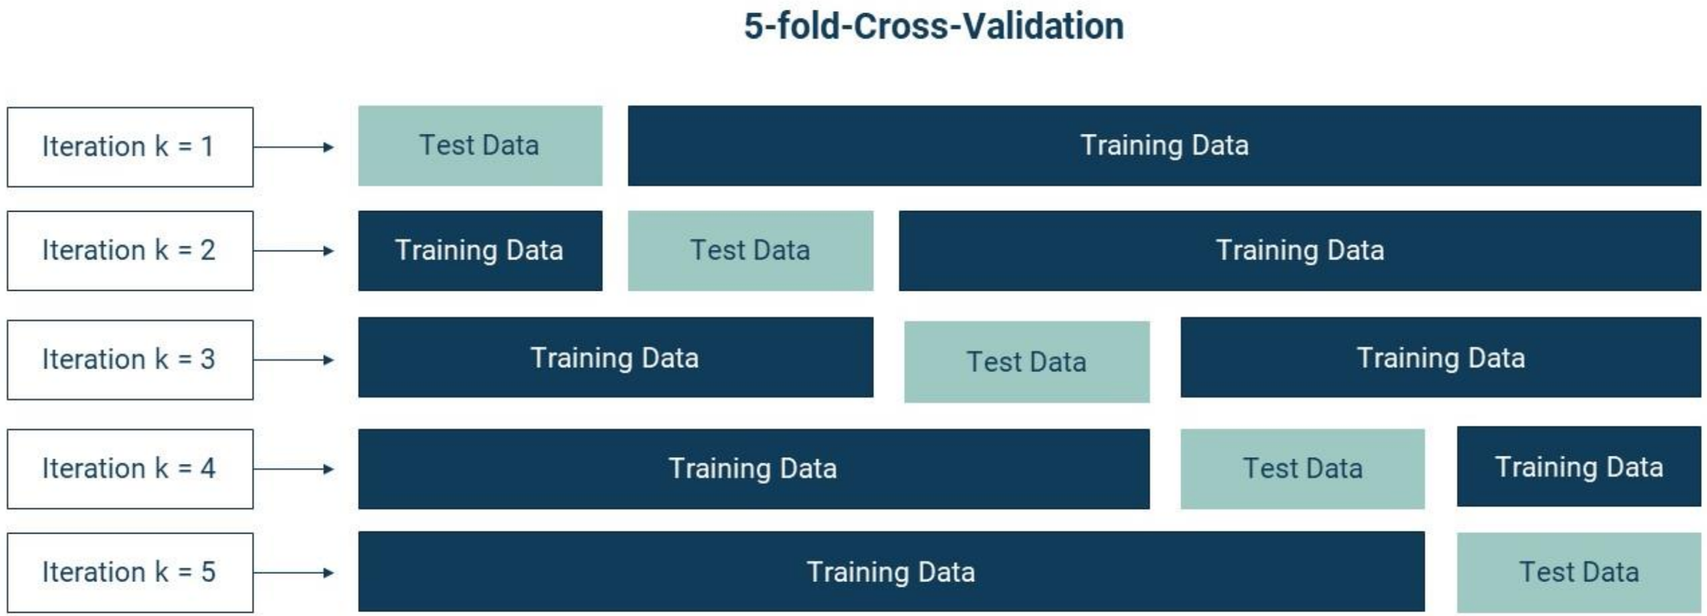

Immagine dell'albero decisionale

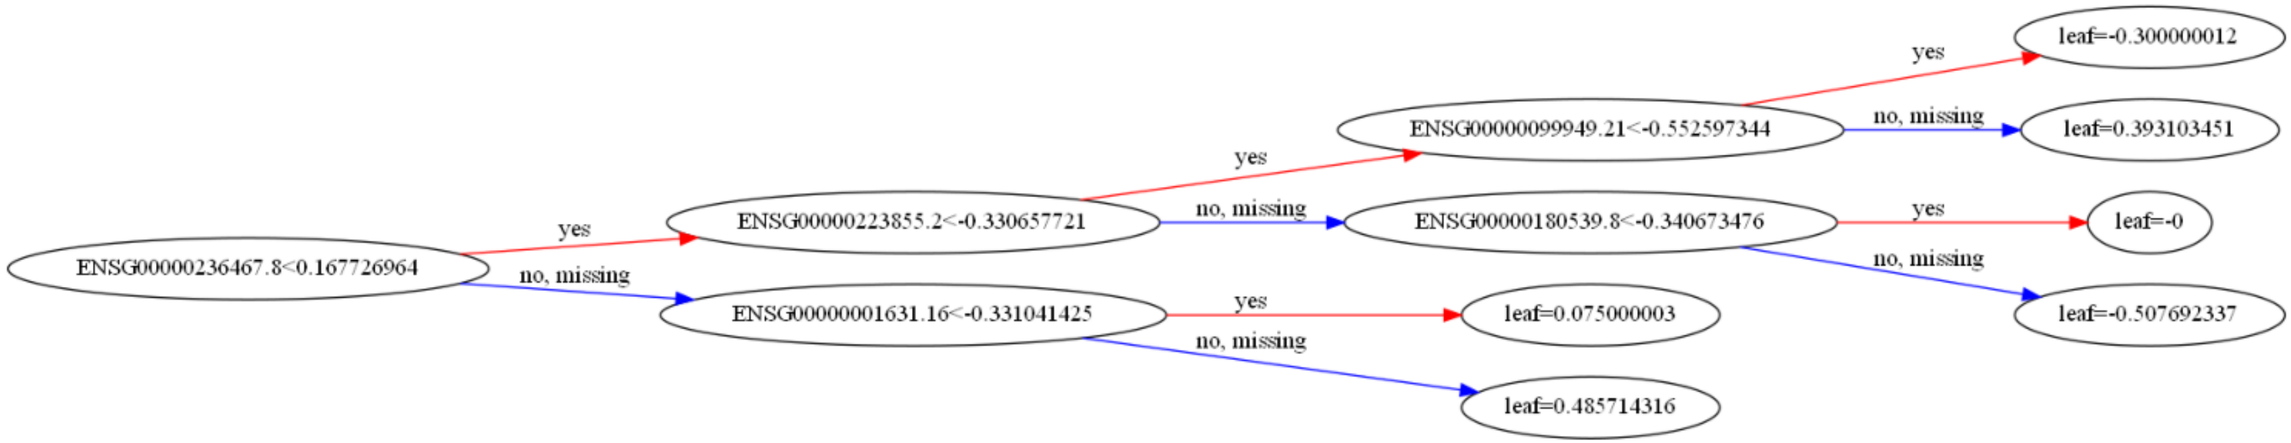

Indice

4. Algoritmo predittivo

- Introduzione
- Creazione del Database
- Algoritmo predittivo
- Risultati
- Conclusioni

Prove con 200 campioni

AUMENTO DEI CAMPIONI E PRIMO TENTATIVO

- Accuracy in training: **67.06%**, ma sul test set solo 50% → possibile **necessità di più dati**.

SECONDO TENTATIVO (PIÙ ITERAZIONI IN RANDOMIZEDSEARCH CV)

- Accuracy in training: 61%, ma test set al 42% → **possibile overfitting**.

TERZO TENTATIVO (STRUTTURA SEMPLIFICATA DEL MODELLO)

- Riduzione della profondità a 10, ma **accuracy invariata.**

Prove con 400 campioni

PROVE CON DIVERSE COMBINAZIONI DI PARAMETRI

Modello Base:
Accuracy Training: **68%**
Accuracy Test: 57%

EFFETTO RIMOZIONE SMOTE

•**Training: 57%**, **Test: 50%**
•**Classe Dead meno rappresentata** → conferma che SMOTE migliora la generalizzazione.

REGOLARIZZAZIONE CON ALPHA E REG_LAMBDA

•**Introduzione di reg_lambda=1 (L2) e alpha=0.5 (L1)** per migliorare la selezione delle feature.
•**Training: 63%**, **Test: 47%** → miglioramento marginale.

In conclusione i risultati ottenuti hanno dimostrato **un'accuratezza variabile tra il 64% e il 68%** per il training set, e il 52% e il 57% per il test set, sebbene ci siano state problematiche relative alla generalizzazione dei dati e al possibile overfitting.

Indice

5. Conclusioni

- Introduzione
- Creazione del Database
- Algoritmo predittivo
- Risultati
- Conclusioni

Conclusioni

Obiettivo del Lavoro raggiunti:

- Creazione di un **database riorganizzato** con dati essenziali dei pazienti.
- Uso del **modello XGBoost** per predire la sopravvivenza basandosi sull'espressione genica (TPM).
- Possibile **supporto alla diagnostica** e alla scelta della terapia più adatta.

Possibili sviluppi futuri:

- **Uso di Informazioni Aggiuntive**
- **Predizione della Sopravvivenza a 5 Anni**

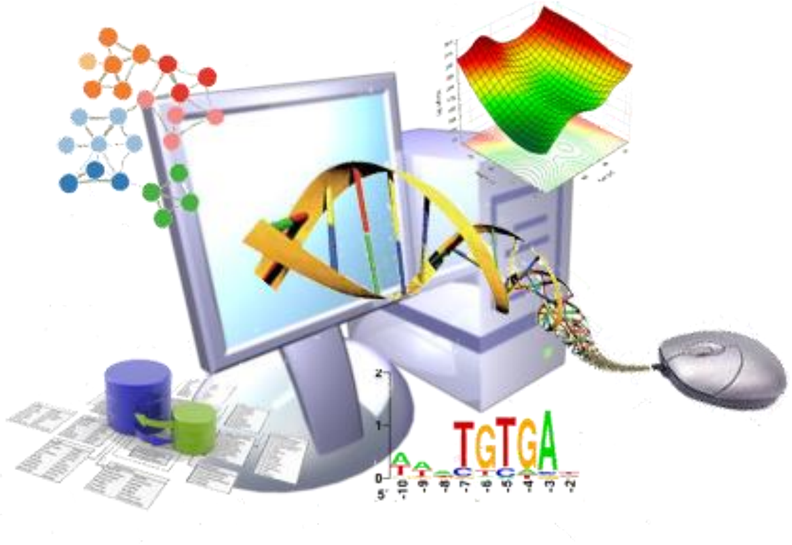

Grazie per l'attenzione!